

UTS METODE KECERDASAN BUATAN

Rosa Amalia Nursinta - 11190940000041

▼ NO.1

1. Jelaskan masing-masing dimensi kecerdasan pada konsep intelligent agent!

Jawab:

Agan cerdas memiliki empat kategori berdasarkan kombinasi dimensi cara inferensi (reasoning) dan tipe kelakuan (behaviour). Berikut ketegori agen dan penjelasannya pada dimensi kecerdasan:

- a) Acting Rationally. Dimensi ini, agen mampu bertindak dengan optimal. Tindakan optimalnya pun belum tentu menyerupai tindakan manusia karena tindakan manusia juga belum tentu optimal. Misalnya, agen mampu memiliki rute terpendek dari suatu kota A ke kota B untuk mengoptimalkan penggunaan sumber daya. Sebagai manusia, bisa saja kita masih mencari rute jalan sesuai yang kita mau/ sesuka hati.
- b) Acting Humanly. Dimensi ini, agen mampu bertindak dan berinteraksi layaknya seperti manusia. Contoh yang terkenal untuk dimensi ini adalah Turing Test. Tujuan dari Turing Test adalah untuk mengevaluasi apakah suatu sistem mampu “menipu” manusia. Misalnya, seorang juri berkomunikasi/ berinteraksi dengan sesuatu di balik layar. Sesuatu yang di balik layar bisa jadi manusia atau program. Program dianggap mampu bertindak/ berinteraksi seperti layaknya manusia, apabila juri tidak dapat membedakan sedang berkomunikasi dengan manusia atau program.
- c) Thinking Rationally. Dimensi ini, agen mampu berpikir secara rasional. Konsep sederhananya seperti konsep logika matematika. Secara umum, dimensi ini lebih cenderung pada pemodelan proses berpikir dengan prinsip optimasi (apa yang harus dilakukan agar hasil optimal).
- d) Thinking Humanly. Dimensi ini, agen mampu berpikir seperti manusia dalam segi kognitif (mampu mengerti apa itu kesedihan atau kesenangan). Secara umum, dimensi ini lebih cenderung pada pemodelan kognitif. Dapat dikatakan, meniru bagaimana proses berpikir di otak terjadi (pemodelan otak).

▼ NO.2

2. Jelaskan apakah menurut anda mungkin untuk menerapkan thinking humanly dan acting humanly pada konsep intelligent agent?

Jawab:

Berdasarkan paparan diatas, dimensi acting humanly dan thinking humanly akan mewujudkan interaksi manusia-komputer seperti manusia-manusia. Agen akan melakukan aksi yang benar dengan cara kita mendefinisikan secara detail, teliti, tepat (precise) apa arti “aksi yang benar”. Namun karena manusia tidak konsisten maka peneliti sulit untuk menemukan model yang tepat sesuai cara berpikir atau tingkah laku manusia yang dimana konsep utama kecerdasan buatan adalah meniru manusia. Karena agen dilatih menggunakan contoh-contoh data buatan manusia,

✓ 0s completed at 10:50 PM



Oleh sebab itu hal yang paling memungkinkan adalah menciptakan agen yang mempunyai dimensi acting rationally.

NO.3

3. Jelaskan tahapan-tahapan (pipeline) dalam membentuk model dalam metode kecerdasan buatan hingga tahap produksi!

Jawab:

1. Proses Pengumpulan Data
2. Exploratory Data Analysis (EDA)

EDA bertujuan sebagai analisa awal terhadap data dan melihat bagaimana kualitas data untuk meminimalkan potensi kesalahan di kemudian hari. Pada proses ini dilakukan investigasi awal pada data untuk menemukan pola, anomali, menguji hipotesis, memahami distribusi, frekuensi, hubungan antar variabel, dan memeriksa asumsi dengan teknik statistik dan representasi grafik. Pada umumnya EDA dilakukan dengan dua cara, yaitu Univariate analysis, bivariate analysis, dan multivariate analysis.

3. Data Processing

Data Processing adalah tahap dimana data diolah lebih lanjut sehingga menjadi siap pakai dalam pengembangan model ML. Proses ini mengubah dan mentransformasi fitur-fitur data ke dalam bentuk yang mudah diinterpretasikan dan diproses oleh algoritma machine learning. Termasuk didalam data processing adalah proses data cleaning dan data transformation.

4. Model Selection

Setelah kita menentukan metode yang cocok untuk data yang ada, kita perlu mengubah hyperparameter untuk mendapatkan performa terbaik dari model. Mengubah nilai hyperparameter saat kita menjalankan algoritma ML akan memberikan hasil atau performa model yang berbeda. Proses menemukan model terbaik model dengan pengaturan hyperparameter yang berbeda ini juga disebut model selection. Dalam konteks machine learning, model selection bisa berarti dua hal: pemilihan learning method atau algoritma ML dan pemilihan hyperparameter terbaik untuk metode machine learning yang dipilih.

5. Monitoring

Model yang telah dipakai dalam tahap produksi masih harus tetap dimonitor untuk menjaga kualitasnya. Pada tahap produksi model bisa saja menemukan data yang tidak dikenali sehingga performa model dapat menurun. Contoh kasus misalnya, jika model merupakan sistem rekomendasi yang menyarankan produk untuk pengguna, maka untuk memantau performa model bisa dengan cara menghitung jumlah produk rekomendasi yang terjual tiap hari. Jika angka ini turun (dibandingkan dengan produk yang tidak direkomendasikan), maka kemungkinan model kita perlu dilatih ulang menggunakan data-data baru.

NO.4

4. Apakah untuk semua kasus dalam suatu penelitian pada permasalahan klasifikasi kita dapat

terus menggunakan metode holdout?Jelaskan alasan anda!

Jawab:

Berdasarkan yang saya pahami, saat proses pengacakan data untuk dibagi sebagai data training dan testing, sangat memungkinkan terjadinya overrepresented pada salah satu atau lebih klasifikasi. Klasifikasi tersebut dominan dibandingkan klasifikasi lainnya, sehingga data training dan testing menjadi tidak representatif. Maka dari itu diperlukan prosedur stratification holdout, dimana prosedur ini menjamin bahwa setiap klasifikasi dapat terwakili pada data training dan testing yang tercipta secara proposional. Hasil proses holdout proporsinya harus sedekat mungkin dengan proporsi aslinya. Maka menurut saya dengan menggunakan metode holdout akan mengoptimalkan pembagian data training dan data testing dalam masalah klasifikasi agar terbentuk data yang representatif dan proporsional.

NO.5

5. Jelaskan beberapa hal yang dapat menurunkan performa model (underfitting) pada permasalahan klasifikasi maupun regresi!

Jawab:

Sebuah model dapat dikatakan underfit jika memiliki eror yang tinggi pada data training. Underfitting menandakan bahwa model tersebut belum cukup baik dalam mengenali pola yang terdapat pada data latih. Misalnya ketika sebuah model dilatih pada data latih yang memiliki 50 sampel coklat dan 50 sampel kacang. Setelah pembelajaran dengan data latih, model malah mengenali pada data latih terdapat 90 sampel coklat dan 10 sampel kacang.

Pada kasus klasifikasi, underfitting ditandai ketika model memiliki akurasi yang rendah pada data training. Pada kasus regresi, underfitting terjadi ketika model memiliki tingkat eror yang tinggi.

beberapa hal yang dapat menurunkan performa model seperti data yang terlalu variatif atau dan model yang terbentuk terlalu sederhana. Umumnya, model gagal untuk mempelajari dataset karena memang tidak diciptakan untuk bisa mempelajari dataset tersebut. Terdapat berbagai jenis data seperti data berupa teks, gambar, audio, atau video. Untuk setiap jenis data ini memiliki model Machine Learningnya tersendiri, perbedaan karakteristik dan kompleksitas membuat kebutuhan untuk model Machine Learning berbeda bagi setiap jenis datanya.

NO.6

6. Berikan pendapat anda dari pernyataan dibawah ini: “Model yang memiliki ukuran performa yang sangat baik di data training sudah cukup untuk melihat kemampuan model secara keseluruhan”

Jawab:

Berdasarkan yang saya pahami, performa yang sangat baik pada data training belum cukup untuk melihat kemampuan model secara keseluruhan, terutama jika proses pembagian data training dan data testing tidak begitu representatif. Sehingga perlu diperiksa terlebih dahulu apakah data training tersebut sudah cukup representatif terhadap semua data atau belum.

Pembagian data training dan data testing yang proporsional dapat dilakukan dengan metode

holdout, sekalipun performa model pada data training sudah sangat baik, saya akan tetap melakukan pengujian kembali model pada data testing untuk benar-benar yakin dengan performa model yang saya miliki.

NO.7

7. Jelaskan fenomena overfitting pada metode kecerdasan buatan!

Jawab:

Overfitting merupakan keadaan dimana model berusaha untuk mempelajari seluruh detail termasuk noise yang ada dalam data dan berusaha untuk mengikutsertakan semua data point ke dalam garis. Overfitting terjadi ketika model memiliki prediksi yang terlalu baik pada data training, namun prediksinya buruk pada data testing. Ketika sebuah model overfit, model tidak dapat melakukan generalisasi dengan baik sehingga akan membuat banyak kesalahan dalam memprediksi data-data baru yang ditemui pada tahap produksi.

Overfitting menjadi masalah karena tujuan kita adalah ingin mendapat tren dari sebuah dataset. Model ini menangkap semua tren tetapi bukan tren yang dominan. Model pun tidak bisa menghasilkan output yang reliable karena tidak memiliki kemampuan untuk dapat memprediksi kemungkinan output untuk input yang belum pernah diketahui.

Jika dianalogikan, overfitting terjadi pada siswa yang menghafal pertanyaan (data point) untuk ujian, bukan mempelajari konsep materi (tren dominan). Sehingga, ketika ujian ia hanya mampu menjawab pertanyaan yang dihafal dan tidak bisa menjawab pertanyaan di luar hafalannya. Maka hasil ujiannya pun akan lebih rendah dari temannya yang belajar dengan memahami konsep materi.

NO.8

8. Jelaskan beberapa hal yang dapat membuat model cenderung overfit pada permasalahan klasifikasi maupun regresi!

Jawab:

Overfitting adalah kondisi dimana model terlalu ekspresif terhadap data training. Maksudnya adalah data training yang digunakan adalah yang terbaik. Sehingga ketika dilakukan testing dengan data berbeda, mengakibatkan berkurangnya akurasi. Hal – hal yang menyebabkan suatu model dikatakan overfitting yaitu :

- Data yang dipakai kurang Variatif. Data yang tersedia dalam training kurang variatif dibandingkan dengan kompleksitas model. Sehingga jika ingin tetap memakai model yang sama dan menghindari overfitting, gunakan dataset yang lebih bervariasi saat training.
- Model terlalu kompleks. Seringkali, model yang dipakai saat training terlalu kompleks untuk dataset yang cenderung tidak terlalu kompleks. Terjadi ketidakcocokan antara model dan data sehingga terjadi overfitting. Maka, kurangi kerumitan model agar terhindar dari overfitting.

NO.9

9. Jelaskan pada kasus seperti apa sebaiknya metode kecerdasan buatan pada permasalahan klasifikasi menggunakan ukuran performansi F_1 Score dibandingkan dengan menggunakan accuracy! (Anda perlu ingat bahwa β tidak harus selalu bernilai 1)!

Jawab:

Terdapat keunggulan dan kelemahan F_1 Score dan Accuracy

Keunggulan accuracy : mudah untuk ditafsirkan. Jika kita mengatakan bahwa suatu model 90% akurat, kita tahu bahwa model tersebut mengklasifikasikan 90% pengamatan dengan benar.

Kelemahan accuracy : tidak memperhitungkan bagaimana data didistribusikan. Misalnya, 90% dari semua pemain tidak direkrut ke NBA. Jika model hanya memprediksi setiap pemain untuk tidak direkrut, model tersebut akan memprediksi hasil dengan benar untuk 90% pemain. Nilai ini tampaknya tinggi, tetapi model tersebut sebenarnya tidak dapat memprediksi dengan benar pemain mana pun yang direkrut.

Keunggulan F_1 Score : mempertimbangkan bagaimana data didistribusikan. Misalnya, jika datanya sangat tidak seimbang (misalnya 90% dari semua pemain tidak mengikuti wajib militer dan 10% mendapatkan wajib militer) maka F_1 Score akan memberikan penilaian kinerja model yang lebih baik.

Kelemahan F_1 Score : lebih sulit untuk ditafsirkan. F_1 Score adalah perpaduan antara presisi dan recall model, yang membuatnya sedikit lebih sulit untuk ditafsirkan.

Dalam praktiknya

Gunakan akurasi pada balanced problem dan tidak ada kerugian besar untuk memprediksi false negative.

Gunakan F_1 Score pada imbalanced problem dan ada kerugian serius untuk memprediksi false negative.

Misalnya, jika kita menggunakan model regresi logistik untuk memprediksi apakah seseorang menderita kanker atau tidak, false negative sangat berbahaya (misalnya memprediksi bahwa seseorang tidak menderita kanker ketika mereka sebenarnya mengidap kanker) sehingga F_1 Score akan menghitung lebih baik model yang memiliki terlalu banyak false negative dibandingkan accuracy.

NO.10

10. Berikan contoh kasus dimana menggunakan accuracy saja pada ukuran performansi model tidak cukup/atau dapat menyesatkan!

Jawab:

model untuk mengidentifikasi teroris yang mencoba naik pesawat. Terdapat 800 juta penumpang rata-rata pada penerbangan AS per tahun dan 19 teroris (yang dikonfirmasi) yang naik penerbangan AS dari tahun 2000–2017 dengan akurasi lebih dari 99 persen, walaupun model ini memiliki akurasi yang hampir sempurna, masalah ini adalah salah satu di mana akurasi bukanlah ukuran yang baik untuk menilai kinerja model. Dalam kasus ini, menyatakan semua penumpang sebagai negatif (bukan teroris) dalam masalah deteksi teroris tidak membantu, dan, sebaliknya, kita harus fokus pada mengidentifikasi kasus positif. Maka kita harus memaksimalkan recall, dimana recall adalah perbandingan jumlah true positive dengan jumlah true positive dan false negative. Jika kita melabeli semua penumpang sebagai teroris

jumlah true positive dan false negative. Jika kita melabeli semua penumpang sebagai teroris, maka recall menjadi 1.0. Namun ini masih bukan pengklasifikasian yang sempurna, seperti kebanyakan konsep dalam ilmu data, ada trade-off dalam metrik yang dipilih untuk dimaksimalkan. Dalam hal recall dan presisi, ketika meningkatkan recall, maka akan mengurangi presisi, dan sebaliknya. Dimana presisi adalah perbandingan jumlah true positive dengan jumlah true positive dan false positive. Dalam kasus di mana kita ingin memaksimalkan antara recall atau presisi, kita dapat menggabungkan dua metrik tersebut menggunakan F_1 Score. Dimana F_1 Score adalah rata-rata harmonik dengan mempertimbangkan presisi dan recall

NO. 11

11. Andaikan anda adalah seorang peneliti yang sedang melakukan penelitian multiclass pada kasus supervised learning. Pada data anda memiliki 4 label kategori, yaitu a, b, c dan d. Anda melatih model S untuk dapat menyelesaikan permasalahan dalam penelitian anda dan menghasilkan confusion matrix seperti dibawah ini dari hasil data test:

		PREDICTED classification					
		<i>Classes</i>	a	b	c	d	Total
ACTUAL classification	a	5	23	17	17		62
	b	10	540	21	14		585
	c	166	96	436	110		808
	d	1	2	5	87		95
		Total	182	661	479	228	1550

Hitunglah dan interpretasikan serta analisis hasil yang anda peroleh:

- Akurasi
- Presisi
- Recall
- Specificity
- F1 Score
- Macro F1 Score
- Micro F1 Score

Jawab:

```
# Diketahui
#Total Dataset#
N_Total = 1550
#True Positive#
TP_A = 5
TP_B = 540
TP_C = 436
TP_D = 87
#True Negative#
```

```
TN_A = 1311
TN_B = 844
TN_C = 699
TN_D = 1314
#False Negative#
FN_A = 57
FN_B = 45
FN_C = 372
FN_D = 8
#False Positive#
FP_A = 177
FP_B = 121
FP_C = 43
FP_D = 141
```

```
# 1. Akurasi
Akurasi = (TP_A + TP_B + TP_C + TP_D) / N_Total
print("Maka nilai akurasi sebesar : %.2f persen" % (Akurasi * 100))

Maka nilai akurasi sebesar : 68.90 persen
```

artinya 68.9% data diprediksi secara benar dari keseluruhan data

```
# 2. Presisi
P_A = TP_A / (TP_A + FP_A)
P_B = TP_B / (TP_B + FP_B)
P_C = TP_C / (TP_C + FP_C)
P_D = TP_D / (TP_D + FP_D)
Presisi = (P_A + P_B + P_C + P_D) / 4
print("Maka nilai presisi sebesar : %.2f persen" % (Presisi * 100))

Maka nilai presisi sebesar : 53.41 persen
```

artinya 53.41% model mampu memprediksi secara benar kelas a / b/ c / d dari keseluruhan kelas yang diprediksi

```
# 3. Recall
R_A = TP_A / (TP_A + FN_A)
R_B = TP_B / (TP_B + FN_B)
R_C = TP_C / (TP_C + FN_C)
R_D = TP_D / (TP_D + FN_D)
Recall = (R_A + R_B + R_C + R_D) / 4
print("Maka nilai recall sebesar : %.2f persen" % (Recall * 100))

Maka nilai recall sebesar : 61.48 persen
```

artinya 61.48% model mampu memprediksi secara benar kelas a / b/ c/ d dari keseluruhan kelas yang sebenarnya.

```
# 4. Specificity
S_A = TN_A / (TN_A + FP_A)
S_B = TN_B / (TN_B + FP_B)
S_C = TN_C / (TN_C + FP_C)
S_D = TN_D / (TN_D + FP_D)
Specificity = (S_A + S_B + S_C + S_D) / 4
print("Maka nilai recall sebesar : %.2f persen" % (Specificity * 100))

Maka nilai recall sebesar : 90.02 persen
```

```
# 5. F1 Score
F1_A = (2 * P_A * R_A) / (P_A + R_A)
F1_B = (2 * P_B * R_B) / (P_B + R_B)
F1_C = (2 * P_C * R_C) / (P_C + R_C)
F1_D = (2 * P_D * R_D) / (P_D + R_D)
print("Maka nilai F1 Score A sebesar : %.2f persen" % (F1_A * 100))
print("Maka nilai F1 Score B sebesar : %.2f persen" % (F1_B * 100))
print("Maka nilai F1 Score C sebesar : %.2f persen" % (F1_C * 100))
print("Maka nilai F1 Score D sebesar : %.2f persen" % (F1_D * 100))
```

```
Maka nilai F1 Score A sebesar : 4.10 persen
Maka nilai F1 Score B sebesar : 86.68 persen
Maka nilai F1 Score C sebesar : 67.75 persen
Maka nilai F1 Score D sebesar : 53.87 persen
```

```
# 6. Macro F1 Score
Macro_F1 = (F1_A + F1_B + F1_C + F1_D) / 4
print("Maka nilai Macro F1 Score sebesar : %.2f persen" % (Macro_F1 * 100))
```

```
Maka nilai Macro F1 Score sebesar : 53.10 persen
```

```
# 7. Micro F1 Score (Hasilnya akan sama dengan akurasi)
Micro_P = (TP_A + TP_B + TP_C + TP_D) / ((TP_A + TP_B + TP_C + TP_D) + (FP_A + FP_B + FP_C
Micro_R = (TP_A + TP_B + TP_C + TP_D) / ((TP_A + TP_B + TP_C + TP_D) + (FN_A + FN_B + FN_C
Micro_F1 = (2 * Micro_P * Micro_R) / (Micro_P + Micro_R)
#Micro_F1 = (TP_A + TP_B + TP_C + TP_D) / ((TP_A + TP_B + TP_C + TP_D) + (0.5 * ((FP_A + FN_A) + (FP_B + FN_B) + (FP_C + FN_C) + (FP_D + FN_D)))
print("Maka nilai Macro F1 Score sebesar : %.2f persen" % (Micro_F1 * 100))
```

```
Maka nilai Macro F1 Score sebesar : 68.90 persen
```

NO.12

12. Buatlah script python untuk nomor 11 diatas dengan dan tanpa menggunakan modul sklearn!

Jawab:

Tanpa Modul Sklearn

```
# Diketahui
#Total Dataset#
N_Total = 1550
#True Positive#
TP_A = 5
TP_B = 540
TP_C = 436
TP_D = 87
#True Negative#
TN_A = 1311
TN_B = 844
TN_C = 699
TN_D = 1314
#False Negative#
FN_A = 57
FN_B = 45
FN_C = 372
FN_D = 8
#False Positive#
FP_A = 177
```



```
-  
FP_B = 121  
FP_C = 43  
FP_D = 141
```

1. Akurasi

```
Akurasi = (TP_A + TP_B + TP_C + TP_D) / N_Total  
print("Maka nilai akurasi sebesar : %.2f persen" % (Akurasi * 100))
```

Maka nilai akurasi sebesar : 68.90 persen

artinya 68.9% data diprediksi secara benar dari keseluruhan data

2. Presisi

```
P_A = TP_A / (TP_A + FP_A)  
P_B = TP_B / (TP_B + FP_B)  
P_C = TP_C / (TP_C + FP_C)  
P_D = TP_D / (TP_D + FP_D)  
Presisi = (P_A + P_B + P_C + P_D) / 4  
print("Maka nilai presisi sebesar : %.2f persen" % (Presisi * 100))
```

Maka nilai presisi sebesar : 53.41 persen

artinya 53.41% model mampu memprediksi secara benar kelas a / b/ c / d dari keseluruhan kelas yang diprediksi

3. Recall

```
R_A = TP_A / (TP_A + FN_A)  
R_B = TP_B / (TP_B + FN_B)  
R_C = TP_C / (TP_C + FN_C)  
R_D = TP_D / (TP_D + FN_D)  
Recall = (R_A + R_B + R_C + R_D) / 4  
print("Maka nilai recall sebesar : %.2f persen" % (Recall * 100))
```

Maka nilai recall sebesar : 61.48 persen

artinya 61.48% model mampu memprediksi secara benar kelas a / b/ c/ d dari keseluruhan kelas yang sebenarnya.

4. Specificity

```
S_A = TN_A / (TN_A + FP_A)  
S_B = TN_B / (TN_B + FP_B)  
S_C = TN_C / (TN_C + FP_C)  
S_D = TN_D / (TN_D + FP_D)  
Specificity = (S_A + S_B + S_C + S_D) / 4  
print("Maka nilai specificity sebesar : %.2f persen" % (Specificity * 100))
```

Maka nilai specificity sebesar : 90.02 persen

5. F1 Score

```
F1_A = (2 * P_A * R_A) / (P_A + R_A)  
F1_B = (2 * P_B * R_B) / (P_B + R_B)  
F1_C = (2 * P_C * R_C) / (P_C + R_C)  
F1_D = (2 * P_D * R_D) / (P_D + R_D)  
print("Maka nilai F1 Score A sebesar : %.2f persen" % (F1_A * 100))  
print("Maka nilai F1 Score B sebesar : %.2f persen" % (F1_B * 100))  
print("Maka nilai F1 Score C sebesar : %.2f persen" % (F1_C * 100))  
print("Maka nilai F1 Score D sebesar : %.2f persen" % (F1_D * 100))
```

Maka nilai F1 Score A sebesar : 4.10 persen
Maka nilai F1 Score B sebesar : 86.68 persen
Maka nilai F1 Score C sebesar : 67.75 persen
Maka nilai F1 Score D sebesar : 53.87 persen

6. Macro F1 Score

Macro_F1 = (F1_A + F1_B + F1_C + F1_D) / 4

print("Maka nilai Macro F1 Score sebesar : %.2f persen" % (Macro_F1 * 100))

Maka nilai Macro F1 Score sebesar : 53.10 persen

7. Micro F1 Score (Hasilnya akan sama dengan akurasi)

Micro_P = (TP_A + TP_B + TP_C + TP_D) / ((TP_A + TP_B + TP_C + TP_D) + (FP_A + FP_B + FP_C

Micro_R = (TP_A + TP_B + TP_C + TP_D) / ((TP_A + TP_B + TP_C + TP_D) + (FN_A + FN_B + FN_C

Micro_F1 = (2 * Micro_P * Micro_R) / (Micro_P + Micro_R)

#Micro_F1 = (TP_A + TP_B + TP_C + TP_D) / ((TP_A + TP_B + TP_C + TP_D) + (0.5 * ((FP_A + F

print("Maka nilai Macro F1 Score sebesar : %.2f persen" % (Micro_F1 * 100))

Maka nilai Macro F1 Score sebesar : 68.90 persen

NO.13

13. Andaikan anda adalah seorang peneliti yang sedang melakukan penelitian pendeteksian penyakit diabetes pada manusia dengan data seperti dibawah ini:

	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	148	72	35	0	33.6	0.627	50	1
1	85	66	29	0	26.6	0.351	31	0
2	183	64	0	0	23.3	0.672	32	1
3	89	66	23	94	28.1	0.167	21	0
4	137	40	35	168	43.1	2.288	33	1
5	116	74	0	0	25.6	0.201	30	0
6	78	50	32	88	31.0	0.248	26	1
7	115	0	0	0	35.3	0.134	29	0
8	197	70	45	543	30.5	0.158	53	1
9	125	96	0	0	0.0	0.232	54	1

****Dimana jika fitur outcome bernilai 1 menandakan bahwa observasi tersebut terjangkit penyakit diabetes. Jelaskan dan berikan contoh penerapan beberapa teknik dibawah ini berdasarkan data diatas:**

- Hold out
- k-fold cross validation
- stratified k-fold cross validation dan
- Leave One Out Cross Validation**

Jawab:

a. Hold out Metode holdout adalah salah satu teknik validasi model yang memakai cara split data, yaitu menjadi training data dan testing data. Metode ini digunakan untuk mendapatkan hasil tingkat akurasi dari sebuah metode pada Machine Learning.

Contoh penerapan pada data diatas adalah misalnya 10 data yang ada dibagi menjadi dua bagian data, yaitu 70% data latih, dan 30% data uji secara acak. Maka, sebanyak 7 data menjadi data latih yang akan digunakan untuk melatih model, sedangkan 3 data lainnya menjadi data uji untuk menguji seberapa baik model dapat memprediksi data baru yang ada. Salah satu kombinasi datanya b. k-fold cross validation Metode k-fold Cross Validation adalah salah satu teknik validasi model. Metode ini merupakan sebuah prosedur pengambilan sampel ulang yang digunakan untuk mengevaluasi model Machine Learning pada sampel data. Prosedur ini memiliki parameter tunggal k yang mengacu pada jumlah grup yang akan dibagi menjadi beberapa sampel tertentu.

Contoh penerapan data diatas adalah misalnya data secara random dibagi menjadi 70% data latih dan 30% data uji. Data latih sebanyak 7 data kemudian dibentuk kedalam $k = 3$ dengan rounding ke bawah. Maka, diperoleh contoh kombinasi dari data training dan testing

c. Stratified k-fold cross validation Sama halnya dengan metode k-fold cross validation yang splitting data secara random, metode ini juga menerapkan metode holdout pada prosesnya. Namun, yang membedakan adalah untuk pemisahan data menjadi data latih dan data uji menggunakan stratifikasi. Stratifikasi merupakan suatu metode atau teknik yang digunakan untuk menguraikan data dan objek menjadi beberapa kelompok sejenis yang lebih kecil dan jelas. Metode ini dianggap lebih even (seimbang) dengan membuat strata (tingkatan-tingkatan) sehingga cukup adil dalam memisahkan dataset.

d. Leave One Out Cross Validation Jika sebelumnya untuk k-fold cross validation menggunakan proses dengan membuat beberapa kelompok data pada data latih, pada LOOCV menggunakan single data. Dataset pada proses ini juga mengalami split menjadi data latih dan data uji, namun dengan single data.

NO.14

14. Buatlah script python untuk nomor 12 diatas dengan dan tanpa menggunakan modul sklearn (tanpa harus fitting model. Anda hanya perlu melakukan splitting pada data)!

Jawab:

```
import pandas as pd
url = "https://raw.githubusercontent.com/susanli2016/Machine-Learning-with-Python/master/di
df = pd.read_csv(url, encoding='unicode_escape')
df.head(10)
```

```
y= df.Outcome

x=df.drop( 'Outcome',axis=1)

x.shape

(768, 8)

train_size=int(0.2*x.shape[0])
test_size=int(train_size)

x_tr=x[0:train_size]
x_tr.shape

(153, 8)

x_t=x[test_size:]
x_t.shape

(615, 8)

y_tr=x[0:train_size]
y_t=y[test_size:]
y_tr.shape

(153, 8)

y_t.shape

(615,)
```

NO.15

15. Jelaskan kelemahan dan kelebihan dari beberapa metric dibawah ini:

- RMSE

- MAE

- MAPE

Anda dapat membuat beberapa kasus seperti ketika terdapat outlier di dalam data yang membuat error menjadi sangat besar atau sangat kecil.

Jawab:

- MAPE

Bentuk MAPE adalah presentase. Jika hanya melihat nilai yang semakin mendekati nol semakin baik, nilai MAPE merupakan nilai terkecil dibandingkan MAE dan RSME.

- MAE

- tidak memperlakukan positif atau negatif pada data yang eror

- tidak terlalu bias untuk nilai eror yang tinggi, tidak mempengaruhi performanya (Tidak sensitif terhadap outlier)

- tidak terlalu bagus untuk data yang banyak
- eror yang besar tidak terlalu ditindak lanjuti
- lebih berguna ketika dampak keseluruhan sebanding dengan peningkatan kesalahan yang sebenarnya.
 - RMSE
- menghitung positif dan negatif nya eror
- hasilnya tetap baik walaupun menghadapi nilai eror yang tinggi
- hasil tetap baik walaupun data semakin banyak
- Menindak lanjuti eror yang besar
- Lebih berguna ketika dampak keseluruhan tidak sebanding dengan peningkatan error.
- Berguna jika kita memiliki nilai tak terduga yang harus kita pedulikan. Nilai sangat tinggi atau rendah yang harus kita perhatikan. Cocok untuk data yang memiliki pencilan besar.
- Jika kita membuat satu prediksi yang sangat buruk, kuadrat akan membuat kesalahan lebih buruk dan itu mungkin membuat metrik cenderung melebih-lebihkan keburukan model. Walaupun setelah di akar hasil masih lebih besar dibandingkan MAE.